Sumário

1 Metodologia

Todo o trabalho foi desenvolvido em ambiente simulado, utilizando o *software* Matlab®. Primeiramente, foram representados no Simulink® dois sistemas de quadricóptero seguindo a modelagem proposta por Balas (2007): ambos submetidos a uma gravidade $g = 9{,}8$ m/s^2 e com comprimento de cada haste $l = 0{,}5$ m. Os dois sistemas diferem entretanto na massa do quadricóptero modelado em cada caso: $m = 2{,}3$ kg e $m = 5$ kg.

O sistema com massa $m = 2{,}3$ kg foi então utilizado para mostrar o desacoplamento das entradas e a instabilidade do sistema. Para tanto, o modelo foi submetido a sinais em pulso em cada uma de suas entradas. Então, a partir da resposta do sistema a essas entradas, foram modelados dois controladores *fuzzy* para estabilizar a atitude e altitude do quadricóptero. Para tanto, foi utilizada a ferramenta *Fuzzy Logic Toolbox* do Matlab®.

A partir dos controladores *fuzzy* desenvolvidos e utilizando a ferramenta *Neuro-Fuzzy Designer* também do Matlab® foram modelados dois controladores neuro-*fuzzy* para controlar a atitude e altitude do *drone*.

Os controladores *fuzzy* e neuro-*fuzzy* foram então comparados tanto para o sistema com massa de $m = 2{,}3$ kg quanto para o de $m = 5$ kg. Os aspectos levados em conta para a comparação dos controladores foram:

- Variação apresentada;
- Tempo necessário para a estabilização;
- Oscilação;
- Sobrelevação apresentada;
- Gasto enérgico apresentado pelos controladores.

Por fim, o sistema com massa m = 2,3 kg, para o qual os controladores foram desenvolvidos, foi submetido a um cenário que envolve ruídos de medição do valor de z para verificar se o controle implementado se mostra robusto.

Em todos os casos, o algoritmo usado pelo Simulink® para a resolução de equações diferencias ordinárias foi o Dormand-Price num contexto contínuo.

2 Desenvolvimento do Trabalho

Este capítulo trata da forma como o trabalho foi desenvolvido de forma a aplicar a metodologia proposta, descrevendo os processos utilizados para a verificação do desacoplamento e instabilidade do sistema (Seção 2.1); a modelagem dos controladores *fuzzy* (Seção 2.2) e neuro-*fuzzy* (Seção 2.3); e a descrição detalhada dos experimentos realizados (Seção 2.4).

2.1 Verificação do Desacoplamento das Entradas

A representação do quadricóptero criada no Simulink® seguindo a modelagem de Balas (2007) é mostrada na Figura 1.

Figura 1 – Representação do quadricóptero no *Simulink*

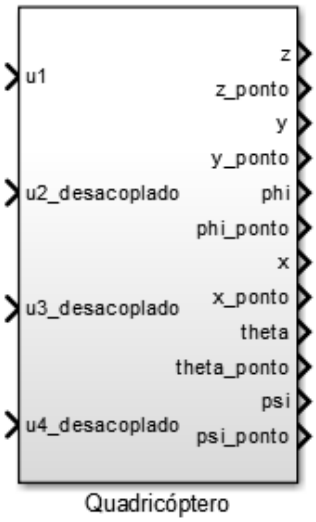

Como se pode ver, o sistema inclui os quatro sinais de entrada seguindo o desacoplamento desenvolvido (*u1*, *u2_desacoplado*, *u3_desacoplado* e *u4_desacoplado*) e com as doze saídas referentes às seis variáveis de configuração x ,y, z, ϕ, θ, ψ indicadas por x, y, z, phi, theta e psi, respectivamente; e suas respectivas variações $\dot{x}$,$\dot{y}$, $\dot{z}$, $\dot{\phi}$, $\dot{\theta}$, $\dot{\psi}$ representadas por x_ponto, y_ponto, z_ponto, phi_ponto, theta_ponto e psi_ponto.

Para mostrar o desacoplamento das variáveis, alternadamente foi aplicado um sinal de degrau a cada uma das entradas. Em cada um dos casos, somente uma entrada era submetida ao degrau, ao passo que as demais eram aterradas. As respostas, a cada um dos experimentos, das variáveis de configuração relativas à altitude e atitude do quadricóptero são mostradas nas Figuras 2, 3, 4 e 5 tomando como estado inicial um quadricóptero estável (ϕ = θ = ψ = 0 rad) a trinta metros de altura (z = -30 m).

Figura 2 – Resposta das saídas z, ϕ, θ e ψ a um entrada em degrau em $u1$

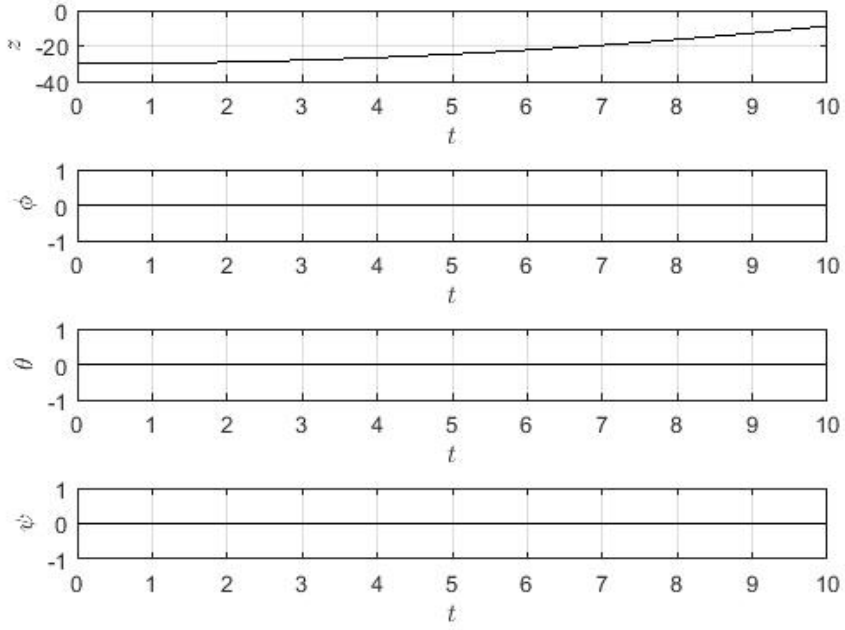

Figura 3 – Resposta das saídas z, ϕ, θ e ψ a um entrada em degrau em $u2\_desacoplado$

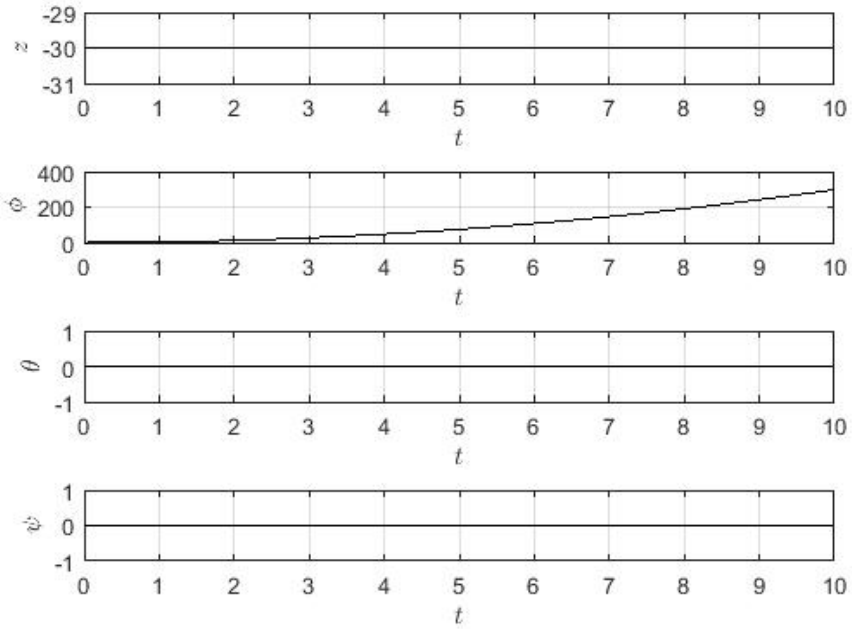

Como se pode ver, cada entrada afeta uma única saída e cada saída é afetada apenas por uma entrada. Com isso, mostra-se o desacoplamento existente que faz com que a entrada $u1$ somente interfira na variável de configuração z; $u2\_desacoplado$ em ϕ; $u3\_desacoplado$ em θ; e $u4\_desacoplado$ em ϕ.

Figura 4 – Resposta das saídas z, ϕ, θ e ψ a um entrada em degrau em $u3\_desacoplado$

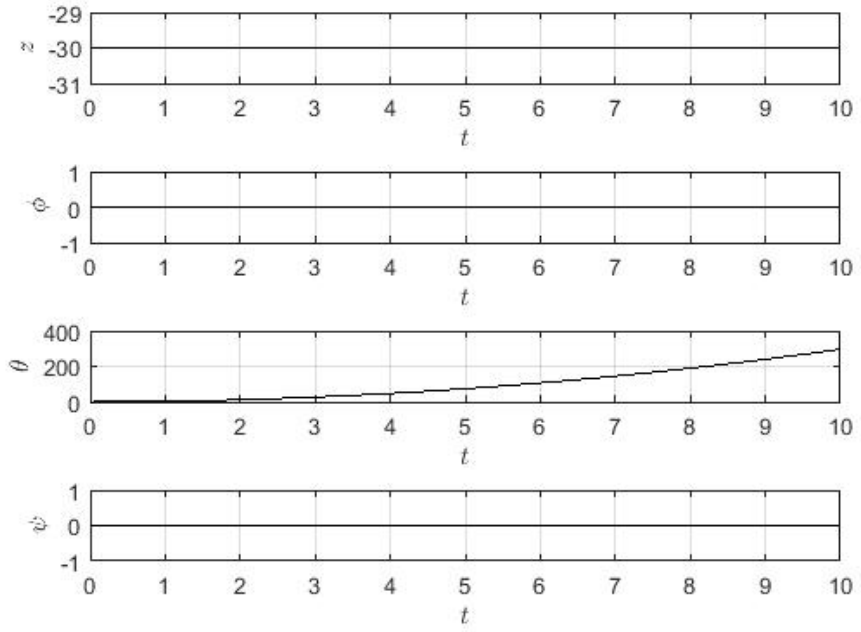

Figura 5 – Resposta das saídas z, ϕ, θ e ψ a um entrada em degrau em $u4\_desacoplado$

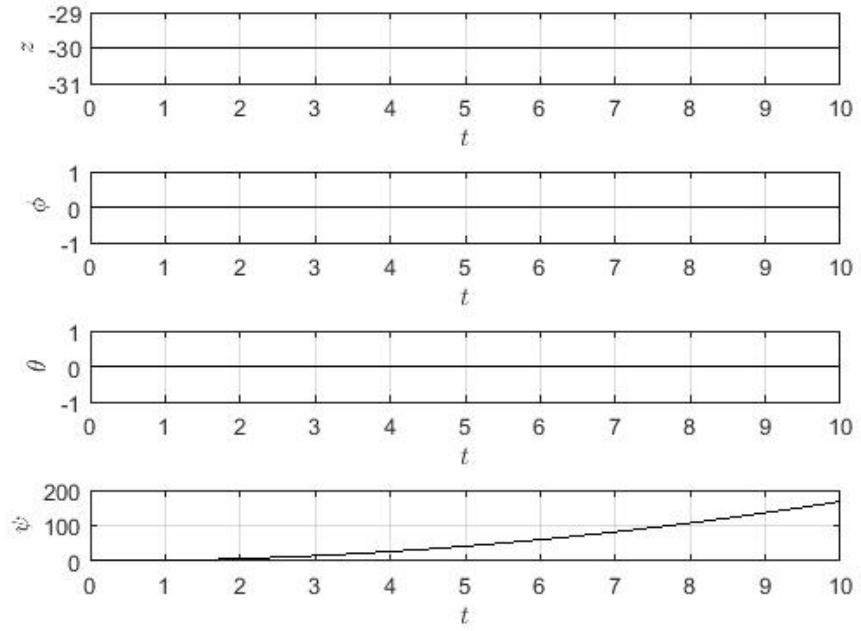

2.2 Controladores Fuzzy

O projeto dos controlador *fuzzy* foi focado na estabilização de atitude e altitude do *drone* modelado de forma a se inserirem no sistema como é mostrado na Figura 6.

Figura 6 – Diagrama do sistema de controle de altitude utilizando controlador fuzzy

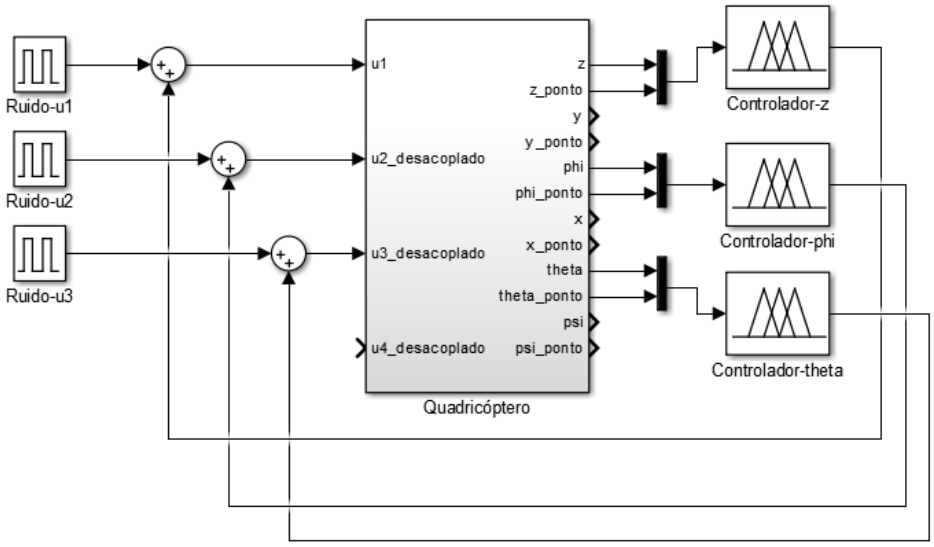

Como se pode ver, três controladores agem no sistema com o objetivo de torná-lo imune a distúrbios representados pelas entradas de ruídos. O `Controlador-z` diz respeito a um controlador de altitude ao passo que os `Controlador-phi` e `Controlador-theta` dizem respeito a controladores de atitude que, pelo fato de o quadricóptero ser simétrico em relação aos eixos x e y, puderam ser representados por um único controlador.

O controlador de altitude possui duas entradas e uma saída. As entradas são referentes à posição vertical do quadricóptero (z) e sua respectiva velocidade ($\dot{z}$), ao passo que a saída diz respeito ao sinal de controle a ser aplicado sobre o sistema para estabilizar sua altitude (u_1).

Utilizando o *Fuzzy Logic Toolbox* do MATLAB, cada variável linguística do controlador *fuzzy* foi dividida em três conjuntos: N (negativo), Z (zero) e P (positivo), tomando como base os trabalhos de Maj e Butkiewicz (2013) e Gao et al. (2014). As regras *fuzzy* definidas para este controlador são mostradas no Quadro 1, e a Figura 7 exibe seu equivalente em superfície.

Quadro 1 – Regras fuzzy para modelagem do controle de altitude

z	$\dot{z}$	u_1
N	-	N
P	-	P
Z	N	N
Z	Z	Z
Z	P	P

O controlador de atitude projetado também possui duas entradas e uma saída. Desta vez, entretanto, as entradas são referentes ao ângulo em relação ao eixo horizontal

Figura 7 – Superfície das regras do sistema de controle *fuzzy* para a altitude do quadricóptero

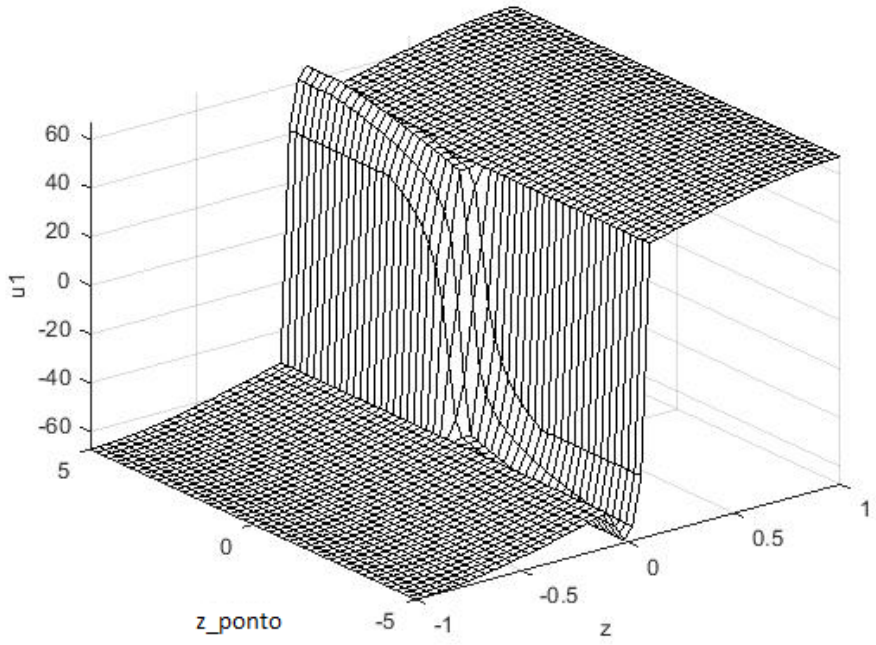

(ϕ ou θ) e sua respectiva variação ($\dot{\phi}$ ou $\dot{\theta}$). Mais uma vez, cada variável linguística foi dividida em três conjuntos: N, Z e P.

As regras que regem o controlador de atitude são sintetizadas no Quadro 2 e podem ser vistas na superfície de regras mostradas na Figura 8.

Quadro 2 – Regras fuzzy para modelagem do controle de atitude

ϕ/θ	$\dot{\phi}/\dot{\theta}$	u_2/u_3
P	P	N
P	Z	N
P	N	Z
N	N	P
N	Z	P
N	P	Z
Z	Z	Z
Z	N	P
Z	P	N

2.3 Controladores Neuro-Fuzzy

A partir dos controladores de atitude e altitude *fuzzy* projetados, foram propostos dois controladores do tipo neuro-*fuzzy*: um para cada dos casos.

Figura 8 – Superfície das regras do sistema de controle *fuzzy* para a atitude do quadricóptero

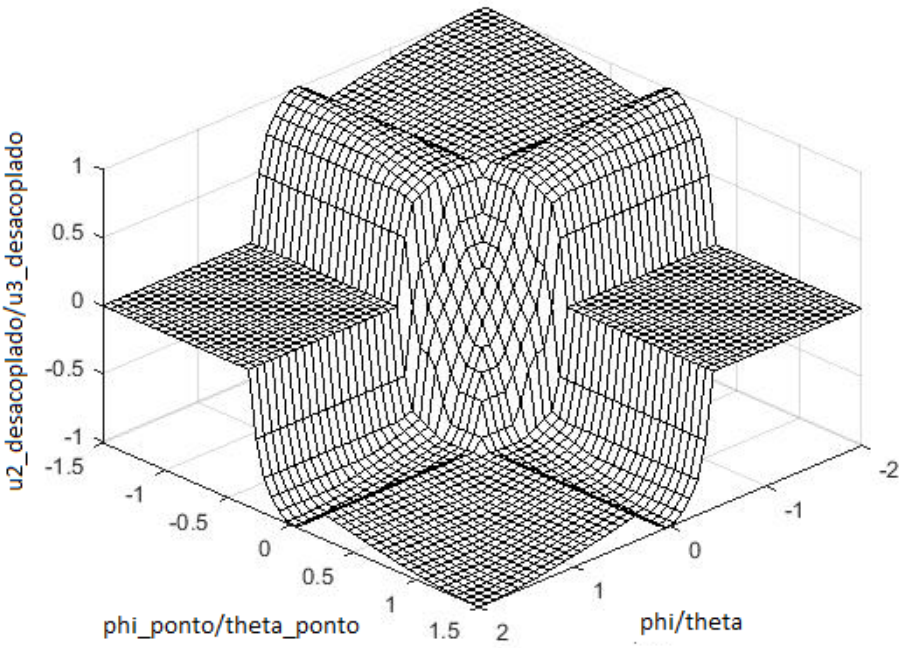

Para tanto, foram utilizados os códigos mostrados nos Apêndices A e B. No processo de criação do controlador de altitude neuro-*fuzzy*, foram gerados trezentos[1] pares de entradas e cada um deles foi submetido ao processo de inferência *fuzzy* utilizando o controlador previamente modelado e descrito na Seção 2.2. Dois terços desses dados foram utilizados para gerar o conjunto de treinamento, representado pela variável `train` e o um terço restante foi armazenado na variável `test` e utilizado para validação do treinamento. Então, utilizando o comando `mam2sug` do MATLAB, foi gerado um modelo fuzzy Sugeno a partir do Mamdani que havia sido modelado e este novo arquivo foi salvo sob o nome `fis_altitude_neuro.fis`.

Feito isto, utilizou-se o comando comando `anfisedit` para abrir o *Neuro-Fuzzy Designer* do MATLAB, cuja interface é mostrada na Figura 9. No campo marcado pelo número 2 na imagem (*Generate FIS*), clicou-se no botão *Load* e se selecionou o arquivo `fis_altitude_neuro.fis` que fora gerado pelo código executado. Após isto, no campo marcado pelo número 1 (*Load Data*), marcou-se *Training* e *worksp* para utilizar uma variável da área de trabalho do MATLAB para treinar a rede. Após clicar em *Load Data*, digitou-se `train`, nome da variável definida no código. Então, no campo marcado pelo número 3, marcou-se *Training Data* e se clicou no botão *Test Now* para executar o treinamento da rede. Após estes passos, a rede neuro-fuzzy foi devidamente treinada e sua estrutura, mostrada na Figura 10, pode ser obtida clicando no botão *Structure* logo

[1] Este valor foi arbitrado por corresponder a uma quantidade razoável para treinar a RNA sem que se alcance o sobre-parametrização, conhecido como *overfitting*.

acima do campo 3. Esta estrutura relaciona as variáveis de entrada e suas funções de pertinência, através das regras fuzzy, à saída do sistema e às suas funções de pertinência, em que cada componente representa um neurônio da RNA obtida.

Figura 9 – Interface gráfica da ferramenta *Neuro-Fuzzy Designer* com destaque aos três campos necessários para treinamento e teste da rede neuro-fuzzy

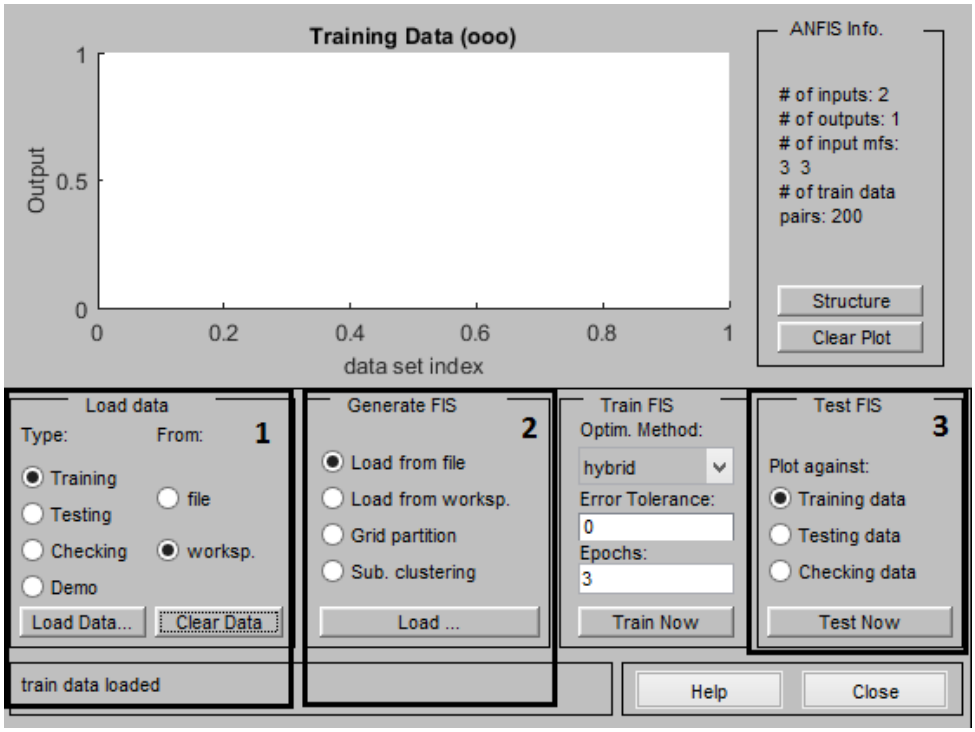

Figura 10 – Diagrama da RNA referente ao controlador neuro-fuzzy para altitude

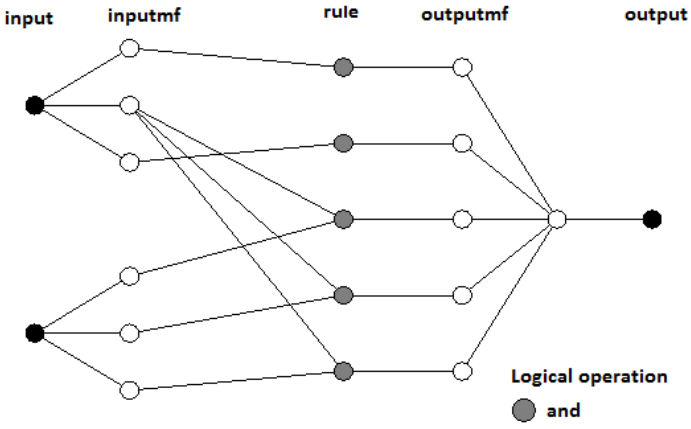

Após o término do treinamento, deve-se submeter a rede ao processo de teste. Para tanto, basta selecionar *Testing* no campo marcado pelo número 1, deixar marcada a opção *workspace*, clicar no botão *Load Data* e escolher a variável `test`, que também foi definida no código executado.

A Figura 11 mostra o gráfico obtido na ferramenta após o processo de treinamento, em que os círculos brancos mostram os dados utilizados no treinamento e os asteriscos pretos indicam o valor referentes a eles obtidos pela rede treinada.

Figura 11 – Resultado obtido pelo treinamento da RNA para controle de altitude

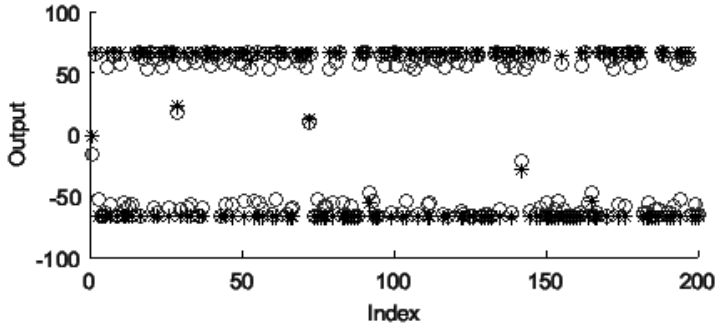

Um processo similar foi aplicado para modelar o controlador de atitude neuro-fuzzy, como mostra o Apêndice B. As Figuras 12 e 13 mostram o diagrama da RNA referente ao controlador neuro-fuzzy para atitude e o resultado obtido pelo seu treinamento respectivamente.

Figura 12 – Diagrama da RNA referente ao controlador neuro-fuzzy para atitude

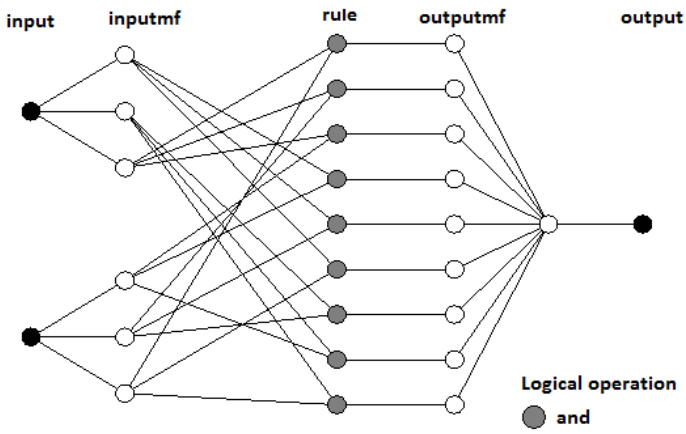

Figura 13 – Resultado obtido pelo treinamento da RNA para controle de atitude

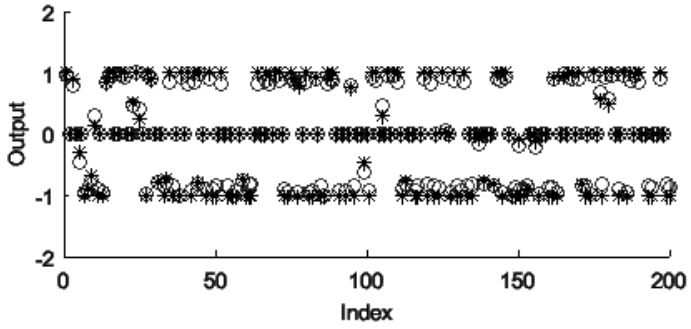

O processo de treinamento determina o comportamento dos controladores neuro-fuzzy projetados, cujas superfícies de regras são exibidas nas Figuras 14 e 15.

Figura 14 – Superfície das regras do sistema de controle neuro-*fuzzy* para a altitude do quadricóptero

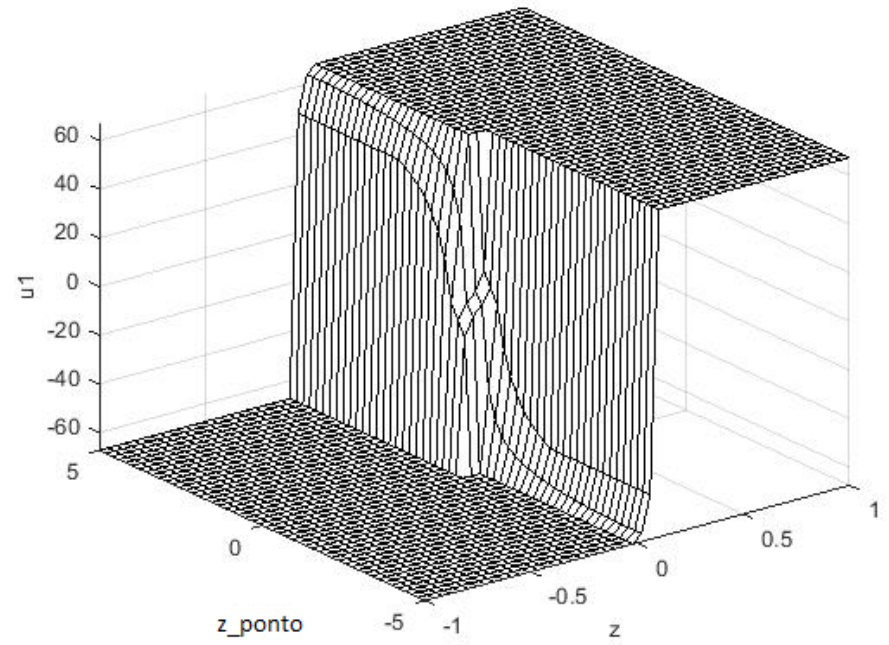

Figura 15 – Superfície das regras do sistema de controle neuro-*fuzzy* para a atitude do quadricóptero

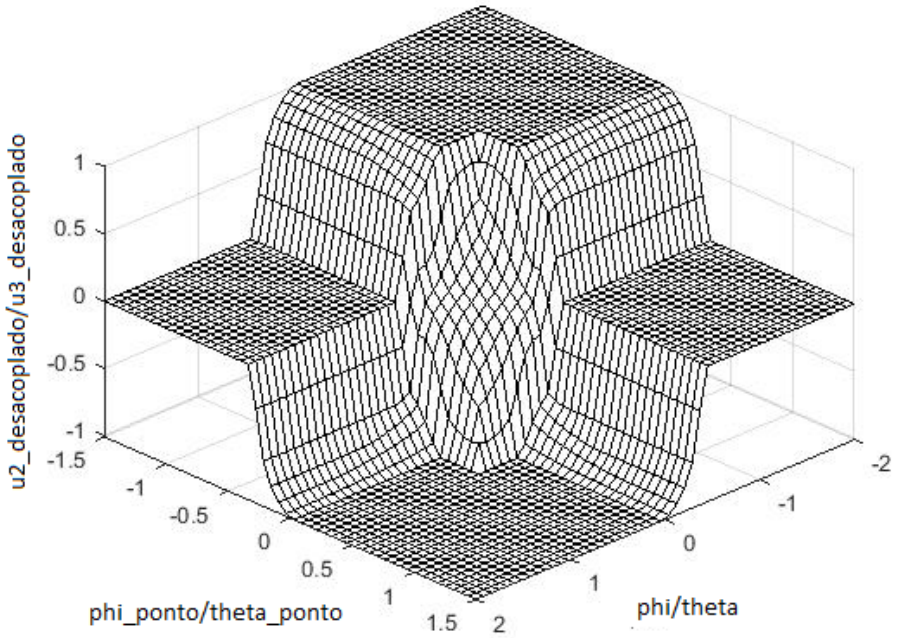

2.4 Experimentos Realizados

Uma vez projetados os controladores *fuzzy* e neuro-*fuzzy*, o sistema foi sujeitado a distúrbios em pulso em atitude e altitude para verificar o funcionamento deles sob condições similares às mostradas quando nenhum controle agia sobre ele fazendo com que o sistema divergisse. Primeiramente, o comportamento de ambos os controladores foi verificado quando atuando sobre o sistema para os quais eles foram projetados, com $g = 9{,}81$ m/s^2, $m = 2{,}3$ kg e $l = 0{,}5$ m.

Em seguida, para testar a robustez de cada controlador, foi feita uma simulação em que eles atuam sobre um sistema cuja massa do quadricóptero é $m = 5$ kg, valor este que foi escolhido por variar o parâmetro massa em mais de 100 %.

Por fim, foi testado o funcionamento do sistema quando um ruído de medição passa a fazer parte dele. Para tanto, um sinal aleatório de ruído foi somado ao valor real obtido de z, como mostrado na Figura 16.

Figura 16 – Representação do quadricóptero no *Simulink* na simulação envolvendo ruído de medição de z

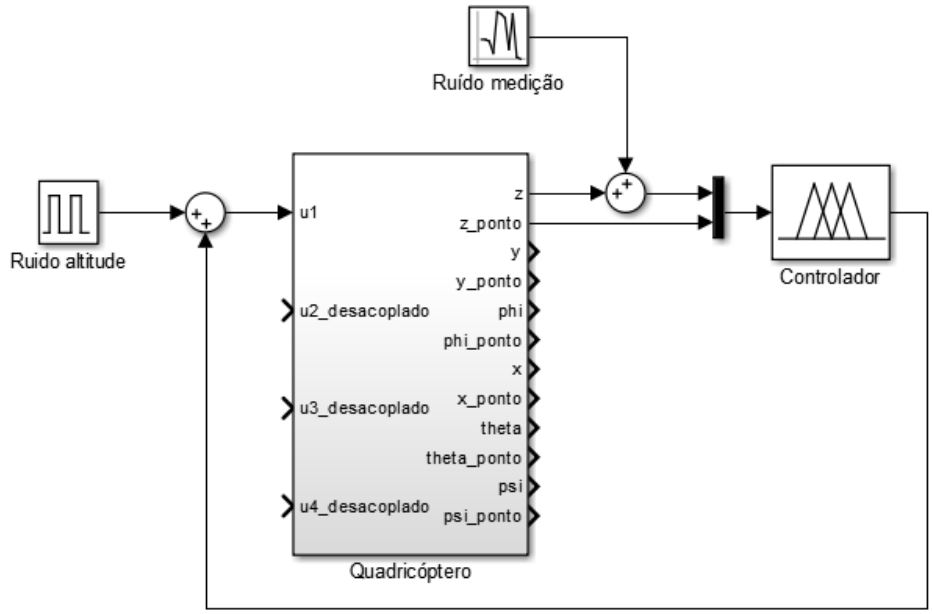

Os resultados obtidos são mostrados no capítulo seguinte.

3 Resultados

A Figura 17 mostra a posição no eixo vertical (z) do *drone*, bem como sua variação no sistema em que atua o controlador *fuzzy* projetado. Como se pode ver, o distúrbio foi devidamente controlado, fazendo com que o quadricóptero retornasse à posição inicial $z = -2$ m e também ao repouso[1] representado por $\dot{z} = 0$ m/s. Nesta figura, entretanto, não fica tão clara a diferença de desempenho dos controladores *fuzzy* e neuro-*fuzzy*, aspecto que pode ser claramente verificado na Figura 18. Como se pode ver, tanto para z quanto para $\dot{z}$, o neuro-*fuzzy* apresenta desempenho melhor. No controle sobre a posição z, o controlador neuro-*fuzzy* apresentou redução do tempo de convergência em 29%, e da variação do sistema em 31%, além de eliminar a sobrelevação apresentada pelo *fuzzy*. Já sobre a velocidade $\dot{z}$, apresentou uma redução no tempo de convergência de 29% além melhorar a variação do sistema em 23%. A partir destes resultados, verifica-se que o controlador neuro-*fuzzy* fez com que o distúrbio fosse melhor absorvido e que sua correção ocorresse mais rapidamente.

Figura 17 – Comparação da resposta das saídas z e $\dot{z}$ no controle de altitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg

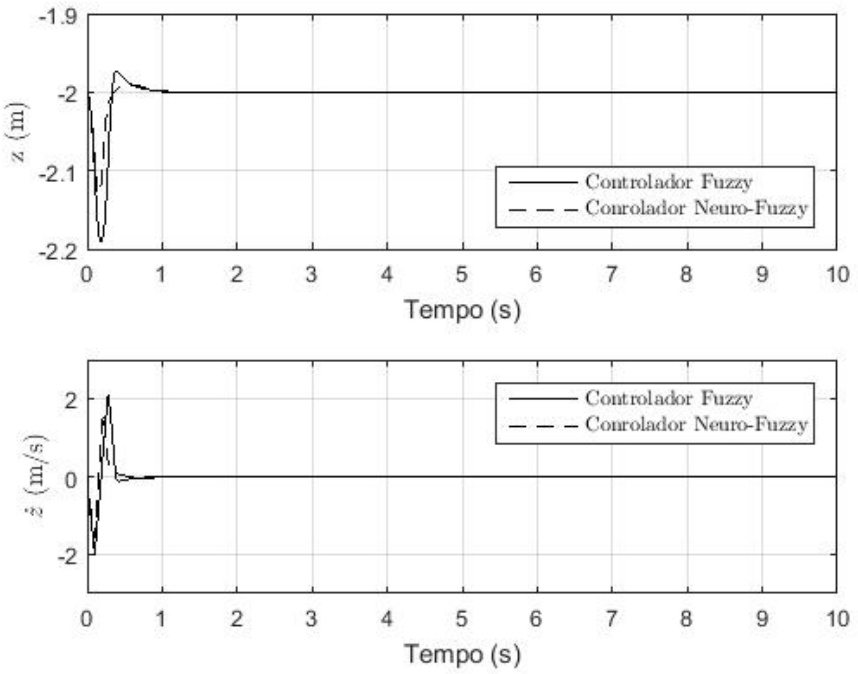

Já a Figura 19 mostra a ação de ambos os controladores. O controlador neuro-*fuzzy* apresentou melhor resultado quanto ao gasto energético, apresentando um gasto 14% menor do que o *fuzzy*.

[1] i.e. velocidade nula

Figura 18 – Comparação em mais detalhes da resposta das saídas z e $\dot{z}$ no controle de altitude fuzzy e neuro-fuzzy para o sistema com massa $m = 2$ kg

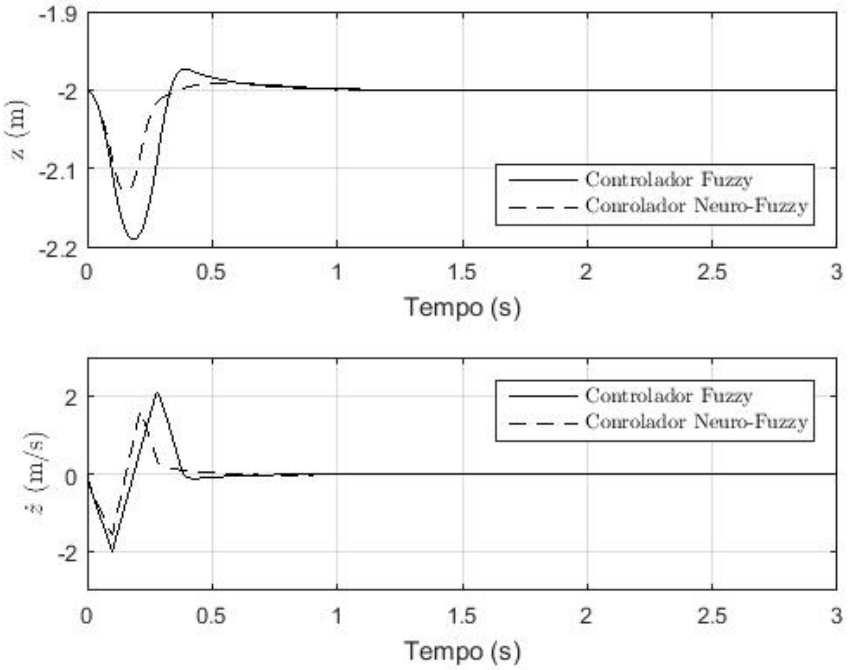

Figura 19 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em altitude do sistema com massa $m = 2$ kg

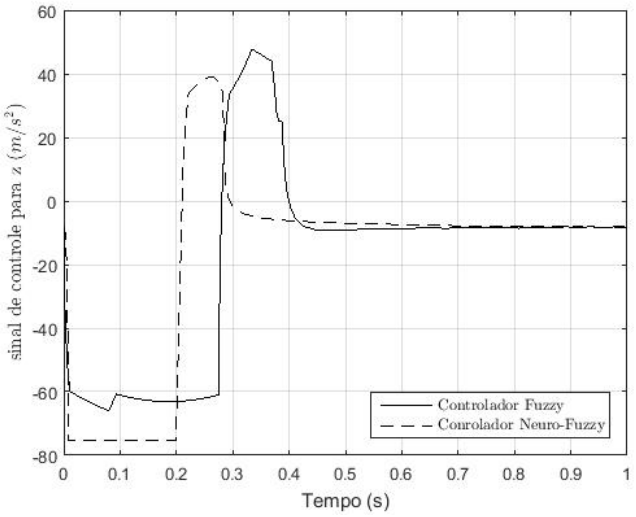

Já as Figuras 20 e 21 mostram a estabilidade de atitude em torno dos eixos x e y (i.e em relação ao plano horizontal XY), representados por θ e ϕ respectivamente. Como se pode ver, ambos os estados são devidamente controlados e, com isto, o *drone* volta à estabilidade horizontal, com ângulos e velocidades angulares nulas no estado permanente.

A partir das Figuras 22 e 23, que mostram as respostas obtidas em mais detalhes,

Figura 20 – Comparação da resposta das saídas ϕ e $\dot{\phi}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg

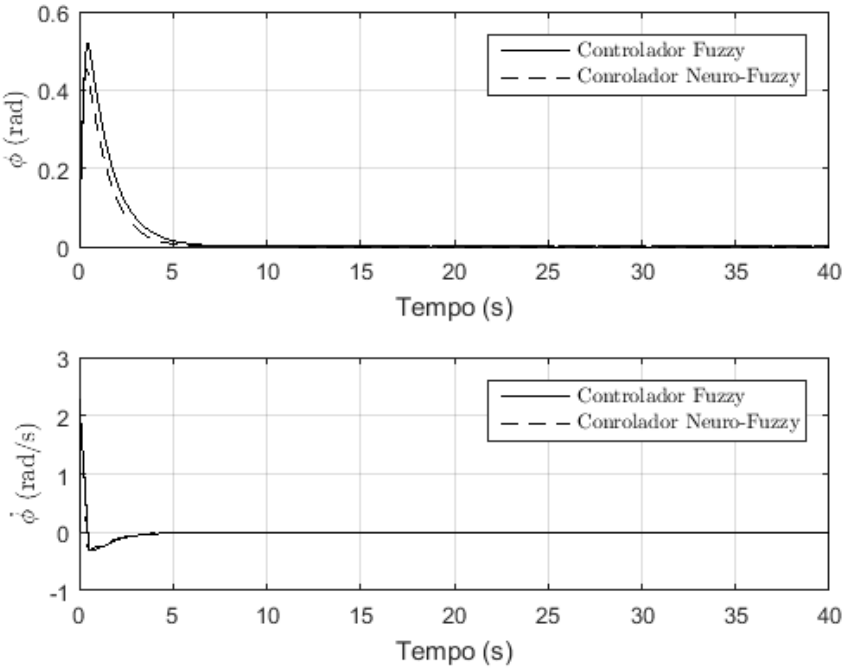

Figura 21 – Comparação da resposta das saídas θ e $\dot{\theta}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg

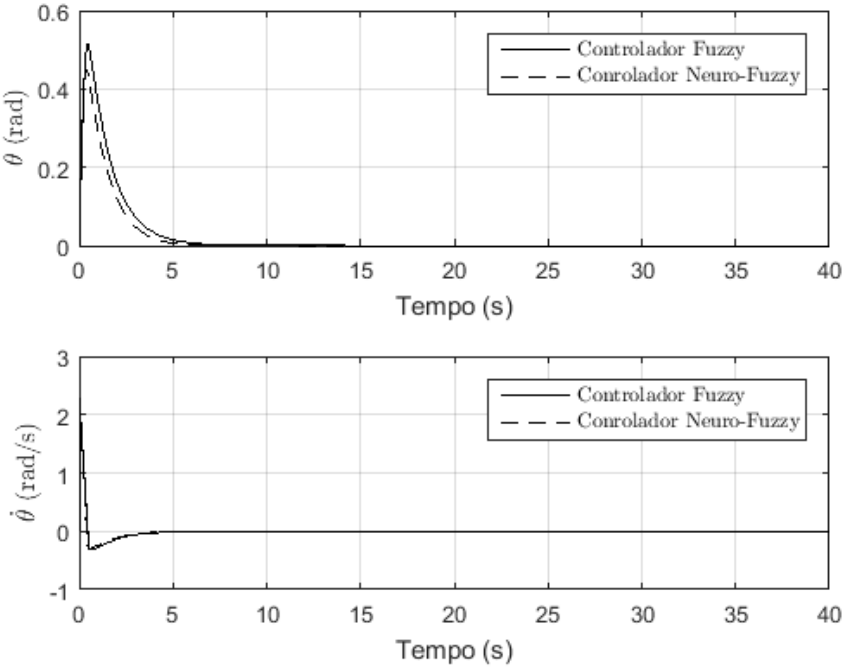

pode-se ver que, mais uma vez o controlador neuro-*fuzzy* mais uma vez teve desempenho superior ao *fuzzy*, fazendo com que os ângulos ϕ e θ convergissem 2% mais rápido, além de reduzir suas variações a 13%. Com relação às velocidades angulares

$\dot{\phi}$ e $\dot{\theta}$, foi capaz de reduzir o tempo de convergência em 3%, não afetando a variação nem a sobrelevação apresentada pelo sistema quando estabilizado pelo controlador *fuzzy*. Desta forma, verifica-se que o controle neuro-fuzzy levou o sistema a uma menor variação, representando que o ângulo máximo de inclinação alcançado pelo *drone* é menor e corrigido mais rapidamente.

Figura 22 – Comparação em mais detalhes da resposta das saídas ϕ e $\dot{\phi}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg

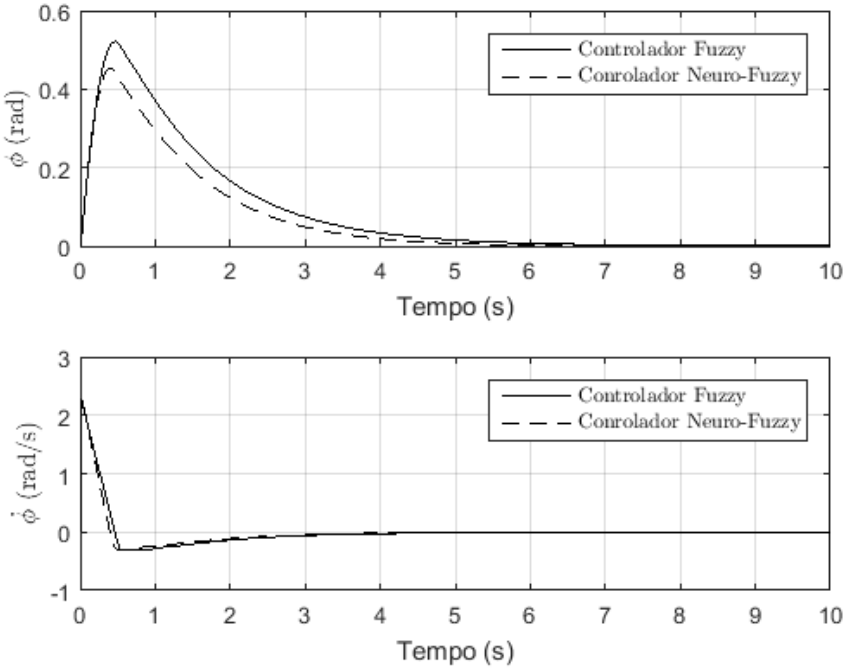

As Figuras 24 e 25 mostra a ação de ambos os controladores no processo de estabilização da atitude do *drone*. Como se pode ver, ambas as respostas são bastante parecidas, devido ao fato de o sistema ser praticamente simétrico em relação aos seus eixos x e y. Em ambos os casos, o controlador neuro-*fuzzy* apresentou resultado inferior ao *fuzzy*, consumindo 12% mais energia do que este.

Além da verificação da eficiência dos controladores atuando sobre o sistema para o qual foram projetados, eles foram testados num sistema em que um dos parâmetros foi acrescido de mais de 100 %, com a massa passando de 2,3 kg para 5 kg.

A resposta dos controladores *fuzzy* e neuro-*fuzzy* para altitude do *drone* nessas circunstâncias são mostradas nas Figuras 26 e 27, sendo que esta segunda é apenas uma forma melhor de comparar a ação dos dois controladores. Como se pode perceber, ambos os controladores levaram à estabilização do sistema, sendo que desta vez cada um obteve desempenho melhor sob determinados aspectos. No controle da posição vertical z, o neuro-fuzzy apresentou tempo de convergência 57% maior, em parte causado por uma sobrelevação, que não foi apresentada pelo *fuzzy*. Em contrapartida, o

Figura 23 – Comparação em mais detalhes da resposta das saídas θ e $\dot{\theta}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg

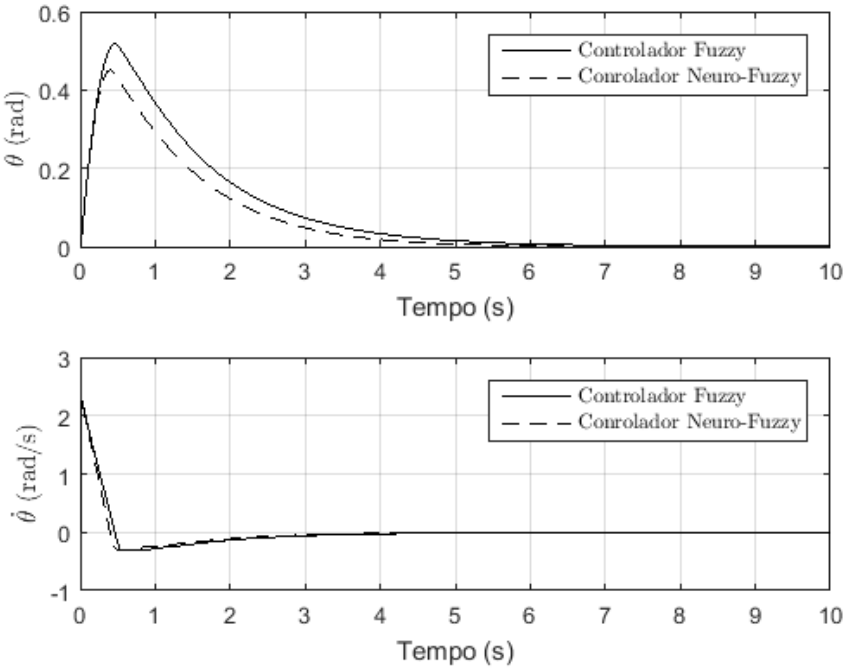

Figura 24 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em atitude do sistema com massa $m = 2$ kg para variável ϕ

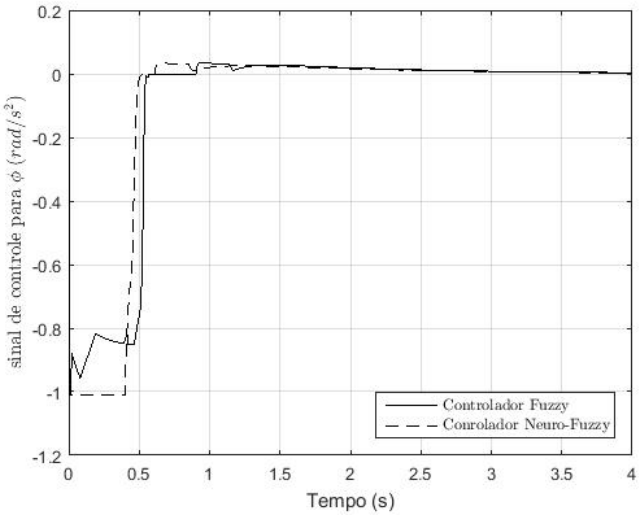

neuro-fuzzy apresentou uma menor variação, a reduzindo em 20% se comparado ao *fuzzy*. Com relação à velocidade $\dot{z}$, o controlador neuro-*fuzzy* apresentou aumento de 23% no tempo de convergência, mas melhorou o sistema nos quesitos variação e sobrelevação, as reduzindo em 16% e 33%, respectivamente. Esses resultados apontam que o quadricóptero, quando submetido ao controle neuro-*fuzzy*, apresentou movimentos mais suaves até ter sua altitude estabilizada, apesar de ter sido necessário mais tempo para que ela ocorresse.

Figura 25 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em atitude do sistema com massa $m = 2$ kg para variável θ

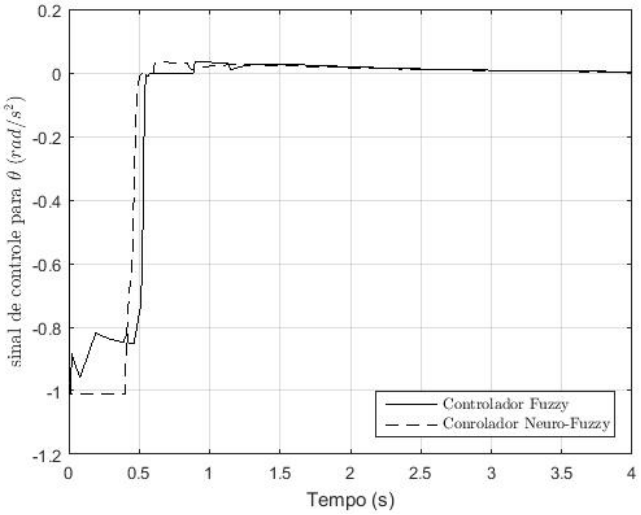

Figura 26 – Comparação da resposta das saídas z e $\dot{z}$ no controle de altitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 5$ kg

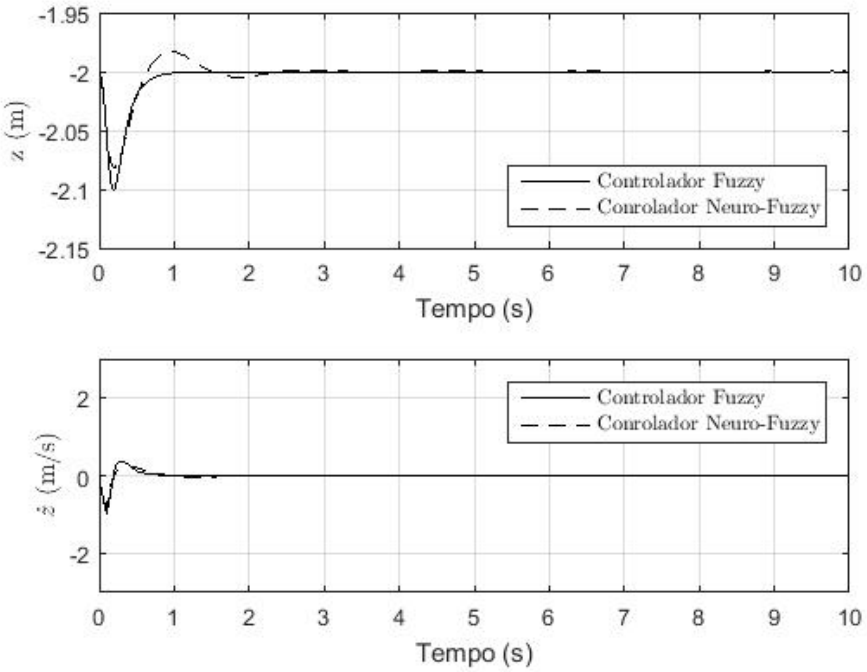

A Figura 28 mostra a ação de ambos os controladores sendo que o neuro-*fuzzy* apresentou um resultado ligeiramente superior ao *fuzzy* com relação ao gasto energético, consumindo 7% menos.

As Figuras 29 e 30 mostram os resultados obtidos pelos controladores de atitude no sistema com massa $m = 5$ kg. Percebe-se que mais uma vez o sistema convergiu ao seu estado de estabilidade com os ângulos nulos e velocidades angulares também

Figura 27 – Comparação em mais detalhes da resposta das saídas z e $\dot{z}$ no controle de altitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 5$ kg

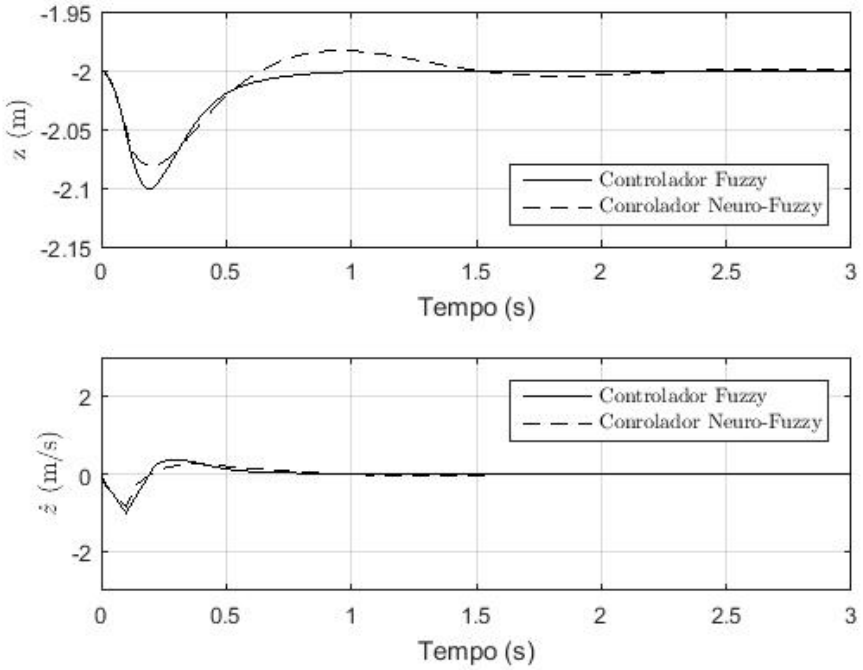

Figura 28 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em altitude do sistema com massa $m = 5$ kg

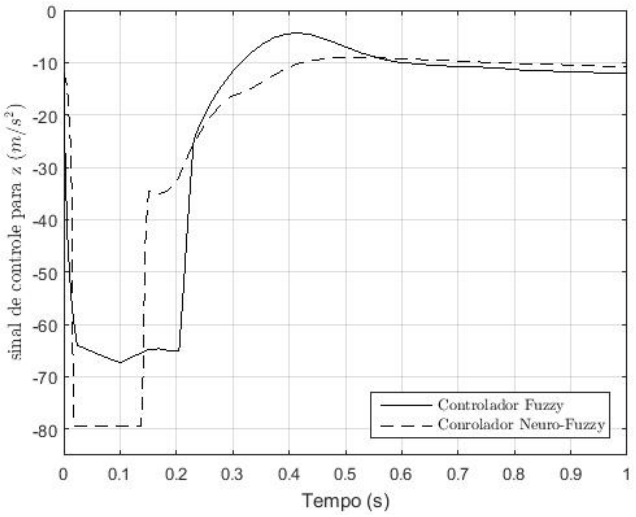

nulas, representando que o quadricóptero, após a ação de controle, tanto *fuzzy* quanto neuro-*fuzzy*, fica estável e com orientação plana[2].

As Figuras 31 e 32 mostram em mais detalhes as repostas obtidas pelos controladores sobre a atitude do sistema com massa $m = 5$ kg. A partir delas, nota-se que mais uma vez o controlador neuro-*fuzzy* apresentou desempenho levemente superior

[2] i.e paralela ao plano XY

ao *fuzzy*. Sobre os ângulos ϕ e θ, a convergência ocorreu 3% mais rapidamente e a variação apresentada reduziu 14%. Já sobre as velocidades angulares $\dot{\phi}$ e $\dot{\theta}$, a redução de tempo de convergência com o neuro-*fuzzy* foi de 2%, mantendo a mesma sobrelevação e variação oferecidas pelo *fuzzy*. Com isto, mais uma vez o controle neuro-fuzzy fez com que o ângulo máximo de inclinação do *drone* fosse inferior ao alcançado pelo sistema controlado pelo *fuzzy*, e além de reduzir o tempo necessário para sua estabilização definitiva.

Figura 29 – Comparação da resposta das saídas ϕ e $\dot{\phi}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 5$ kg

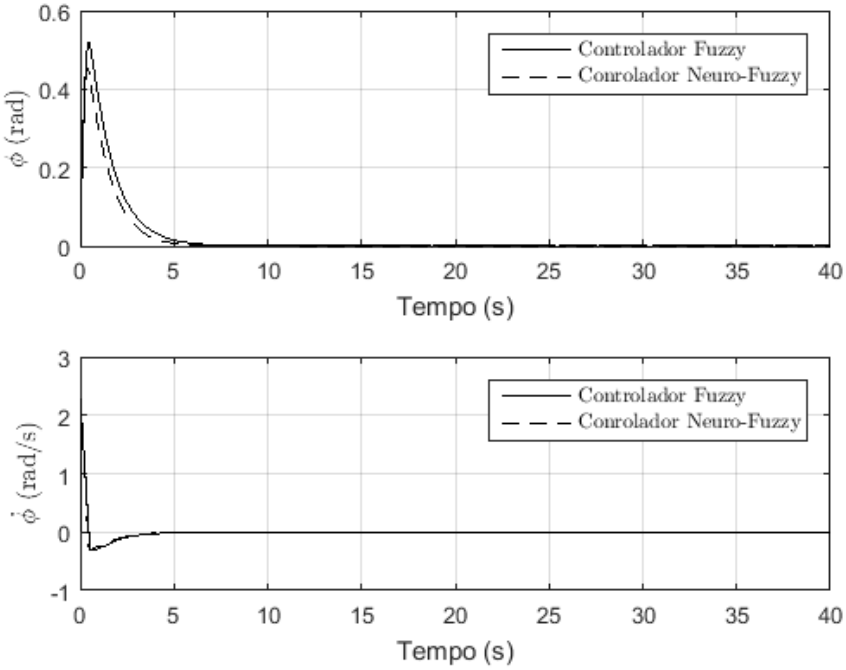

Por fim, as Figuras 33 e 34 mostram a ação de ambos os controladores no processo de estabilização da atitude do *drone*. Assim como para o sistema com massa $m = 2$ kg, em ambos os casos o controlador neuro-*fuzzy* apresentou resultado inferior ao *fuzzy*. Desta vez, entretanto, o consumo foi 10% maior.

Já no teste de robustez a ruídos de medição dos controladores desenvolvidos, a Figura 35 mostra a resposta do sistema ao ruído de medição representado pela Figura 36. A mesma resposta é mostrada na Figura 37, porém com maiores detalhes, permitindo uma melhor comparação do sistema controlado pelos diferentes controladores.

Como se pode ver, o controlador neuro-*fuzzy* obteve uma resposta melhor se comparado ao *fuzzy*, apresentando uma redução em 39 % na variação do sistema, além de uma convergência 13 % mais rápida. Além disso, nota-se que, com o controlador neuro-*fuzzy*, o sistema ficou mais estável, apresentando menores variações, apresentando assim, uma melhor resposta ao sistema sujeito a ruídos.

Figura 30 – Comparação da resposta das saídas θ e $\dot{\theta}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 5$ kg

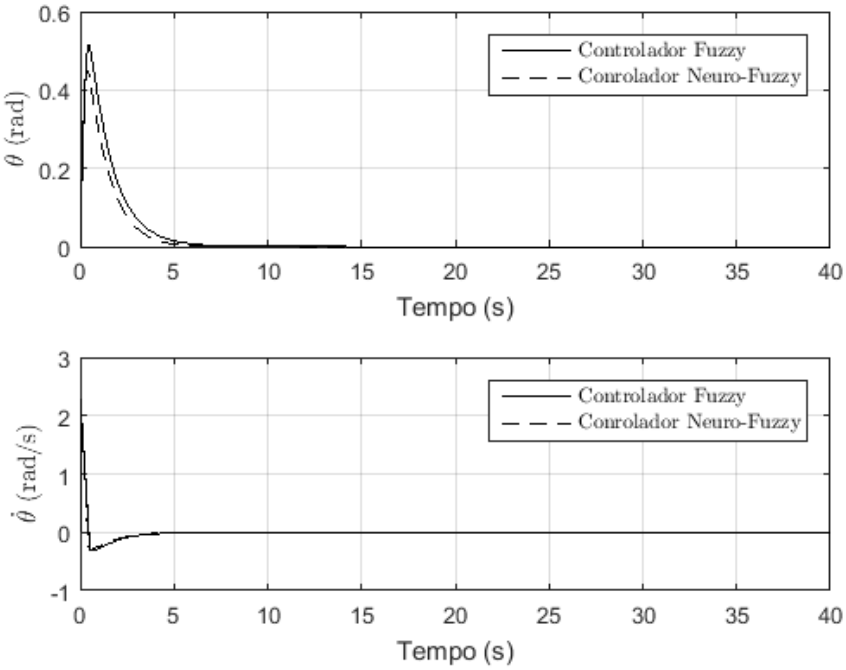

Figura 31 – Comparação da resposta das saídas ϕ e $\dot{\phi}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 5$ kg

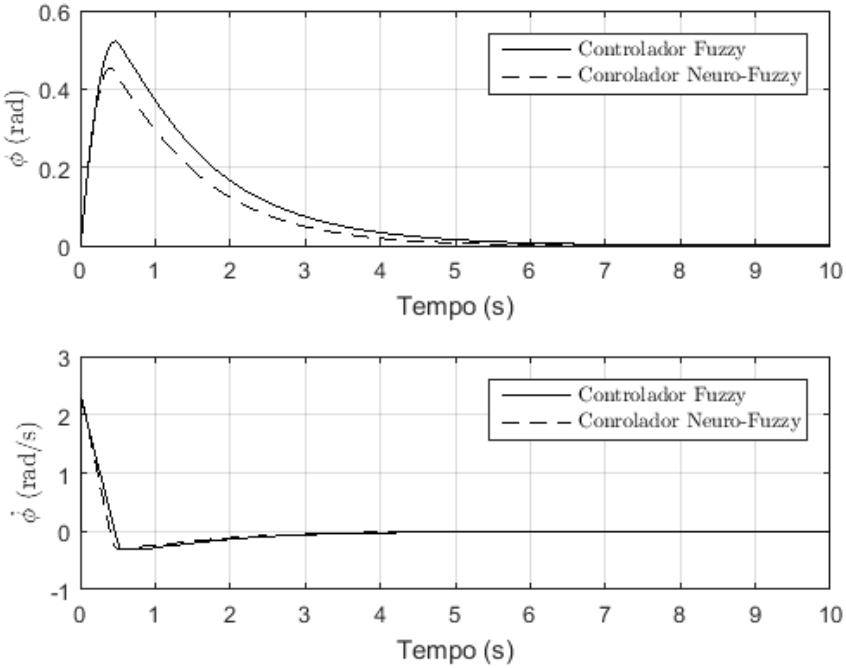

Por fim, a Figura 38 mostra a resposta dos dois controladores ao longo tempo. Como se pode ver, o controlador neuro-*fuzzy* apresentou eficiência energética 33 % superior ao *fuzzy* até o momento de convergência. Além disso, percebe-se que a ação do

Figura 32 – Comparação da resposta das saídas θ e $\dot{\theta}$ no controle de atitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 5$ kg

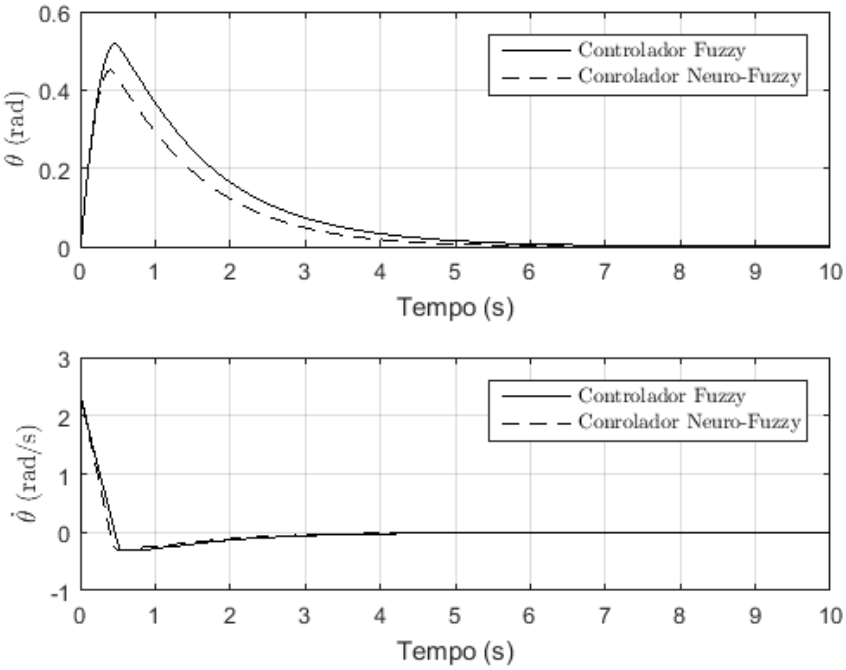

Figura 33 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em atitude do sistema com massa $m = 5$ kg para variável ϕ

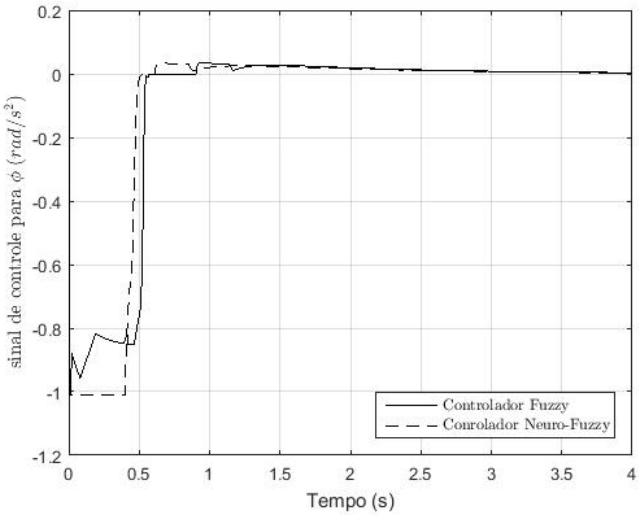

controlador neuro-*fuzzy* é muito mais sutil na absorção dos ruídos, levando assim a um grande ganho de desempenho energético a longo prazo.

Figura 34 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em atitude do sistema com massa $m = 2$ kg para variável θ

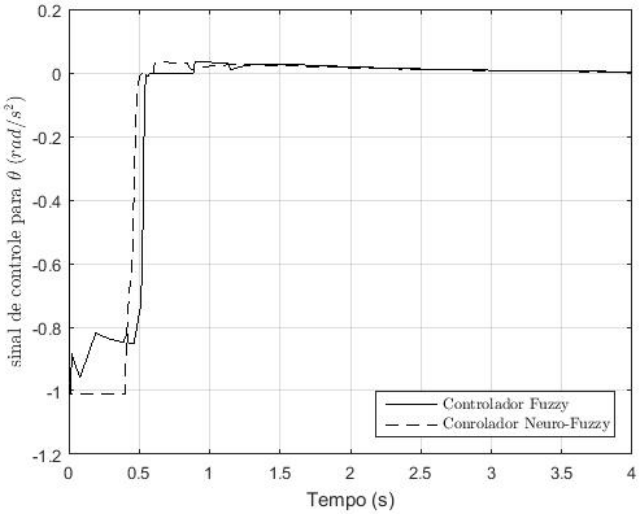

Figura 35 – Comparação da resposta das saídas z e $\dot{z}$ no controle de altitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg sujeito a ruídos de medição da variável z

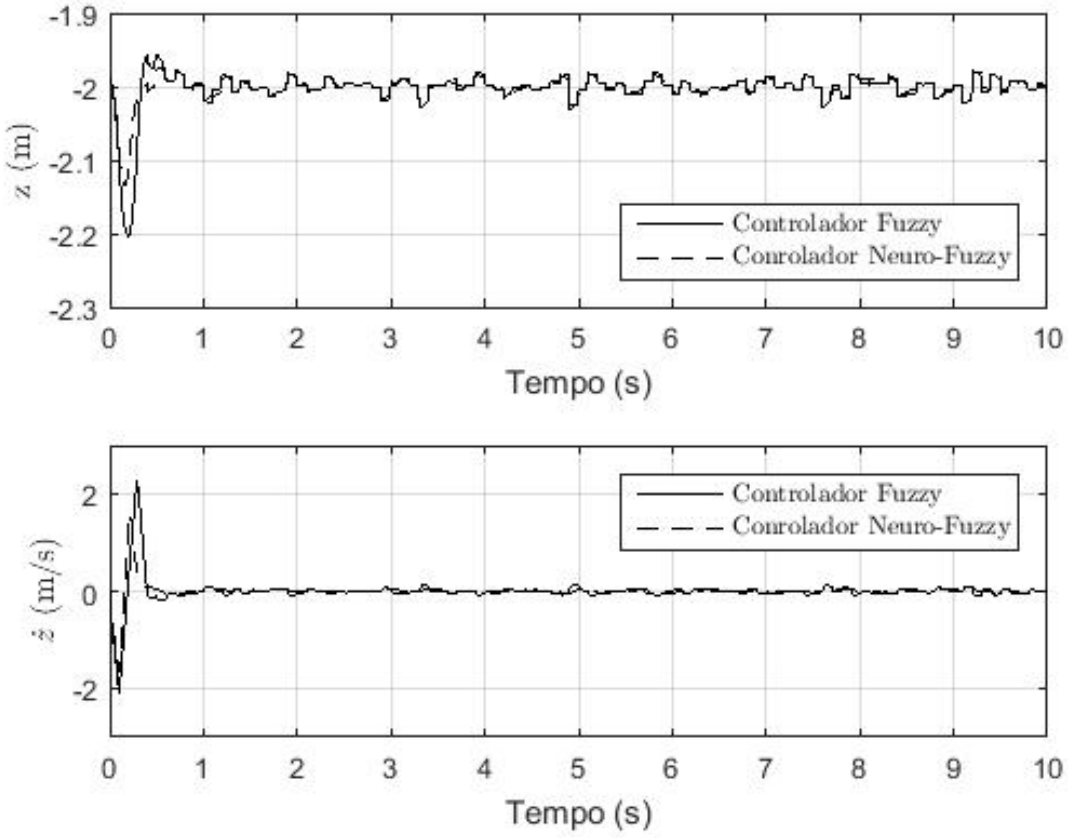

Figura 36 – Sinal de ruído de medição sobre o valor real da variável z

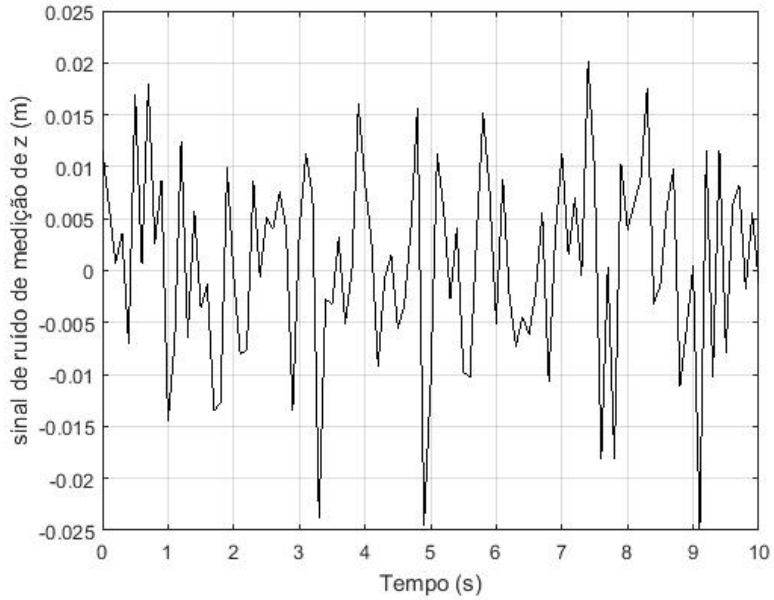

Figura 37 – Comparação em mais detalhes da resposta das saídas z e $\dot{z}$ no controle de altitude *fuzzy* e neuro-*fuzzy* para o sistema com massa $m = 2$ kg sujeito a ruídos de medição da variável z

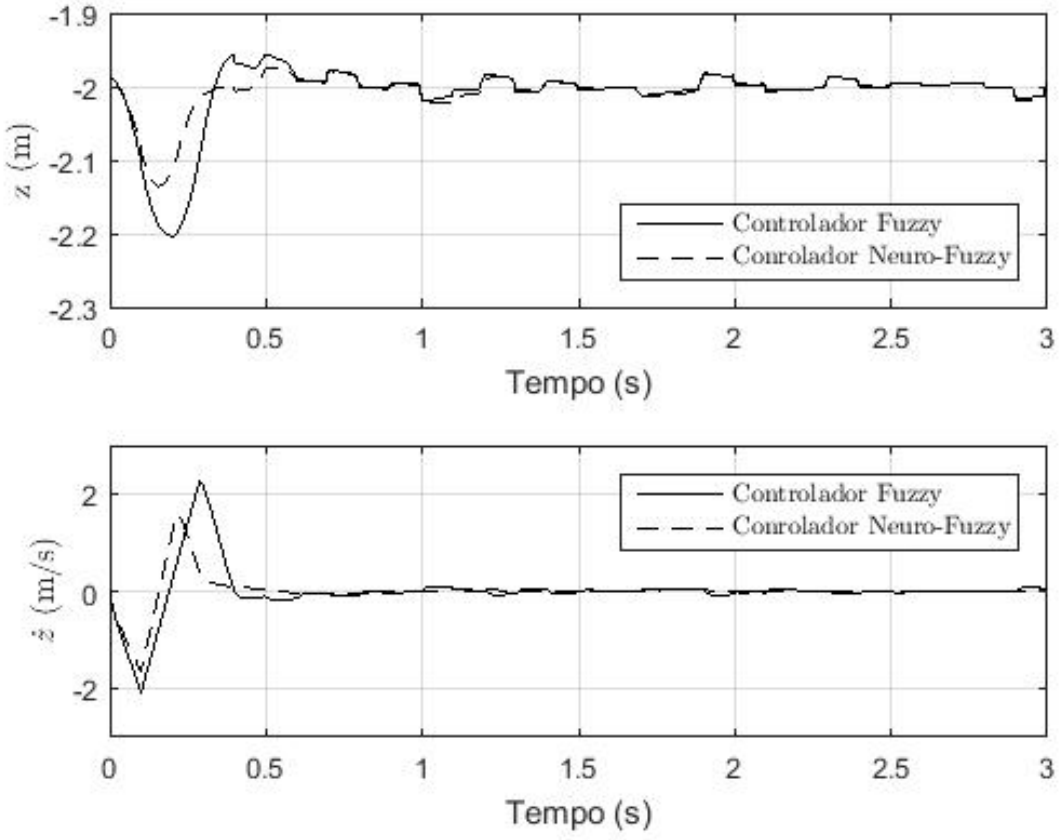

Figura 38 – Comparação da ação dos controladores *fuzzy* e neuro-*fuzzy* na estabilização em altitude do sistema com massa $m = 2$ kg sujeito a ruídos de medição da variável z

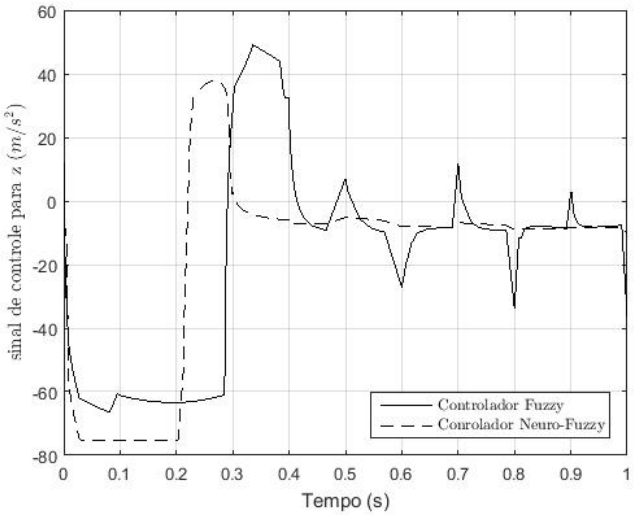

3.1 Análise Consolidada dos Resultados

Como se pode ver, os controladores de atitude e altitude tanto fuzzy quanto neuro-fuzzy foram eficientes levando à estabilização do sistema em todos os casos testados, inclusive na situação em que a massa do sistema foi aumentada em mais de 100 %. Isso indica que estes controladores podem ser utilizados, por exemplo, em situações em que o drone precisaria transportar uma carga que tenha sua massa ou até mesmo uma superior.

Em quase todos os casos, nota-se um comportamento do controlador neuro-fuzzy superior ao do *fuzzy*, o que já era esperado tendo em vista que o primeiro alia o poder do segundo às vantagens das RNAs, fazendo com que, a partir de um treinamento supervisionado utilizando o próprio modelo *fuzzy*, possa se construir um controle mais abrangente e com resposta melhorada. Além disto, verificou-se uma melhora no consumo energético no controle de altitude ao utilizar o controlador neuro-*fuzzy*. No controle de atitude, entretanto, o controlador neuro-*fuzzy* apresentou pior eficiência energética.

Já no experimento envolvendo ruídos de medição, o controlador neuro-*fuzzy* de altitude se mostrou muito superior ao *fuzzy*, apresentando menor variação e menor tempo de convergência além de uma eficiência energética muito melhor, atuando de forma muito sutil para as correções dos ruídos incluídos no sistema ao passo que o *fuzzy* gasta muito mais energia para fazer cada uma dessas correções.

Estes resultados mostram que, de fato, as técnicas de Inteligência Computacional podem ser aplicadas para projetar controladores eficientes e robustos para atuar sobre

sistemas multivariável e que, além disto, o poder de treinamento dos ANFISs realmente é capaz de fazer com que o desempenho de controladores neuro-*fuzzy* seja melhorado se comparado ao daqueles puramente *fuzzy*, tanto com relação à qualidade de resposta quanto à eficiência energética.

4 Conclusão

Ao longo deste trabalho, discorreu-se sobre o crescente uso de estratégias da Inteligência Computacional para implementar controladores de sistemas não lineares. Além disto, como foi mostrado pelos experimentos realizados, o uso de controladores devidamente projetados é fundamental para fazer com que esses sistemas instáveis atuem da forma planejada e possam ser estabilizados.

No contexto deste trabalho, o sistema controlado é um quadricóptero e as variáveis são referentes à sua atitude e altitude, representando portanto um controle multivariável. As alternativas propostas como controladores foram o *fuzzy* e o neuro-*fuzzy*. A opção pelo primeiro se deveu ao fato de ele permitir a modelagem a partir de variáveis e termos linguísticos, além de acrescer robustez ao sistema. Já a opção pelo segundo, neuro-fuzzy, foi devido ao fato de este agregar as características de RNAs aos sistemas fuzzy, possuindo um poder de aprendizado capaz de melhorar sua performance.

De fato, os resultados mostram que o controlador neuro-*fuzzy* realmente obteve melhor desempenho. No controle de altitude, reduziu o tempo de convergência em 29% e a variação do sistema em 31% além de eliminar a sobrelevação apresentada pelo *fuzzy*. O controle neuro-*fuzzy* de atitude também apresentou melhoras, apesar de não tão significativas quanto essas: reduziu o tempo de convergência em 2% e a variação do sistema em 13%.

Além disto, num teste para verificar a robustez dos controladores, a massa do sistema foi acrescida em 117%, passando de 2 kg para 5 kg. Neste novo contexto, o controlador de atitude neuro-*fuzzy* mais uma vez foi superior ao *fuzzy*, reduzindo o tempo de convergência em 3% e da variação em 14%. Já no controle de altitude, o único fator melhorado pelo neuro-*fuzzy* foi a variação do sistema, sendo reduzida em 20%, ao passo que seu tempo de convergência cresceu 57%, além de ter sido inserida uma sobrelevação na resposta.

Apesar das diferenças de desempenho, os controladores *fuzzy* e neuro-*fuzzy* tanto para atitude quanto para altitude do sistema foram capazes de estabilizá-lo, mesmo quando submetido a uma variação substancial de parâmetros, que foi representada pelo aumento da massa em mais de 100%, mostrando assim a robustez intrínseca a ambos os controladores.

Desta forma, mostra-se que se podem usar técnicas de IC para controlar, de forma eficiente, sistemas não-lineares complexos e, além disso, que controladores neuro-*fuzzy* podem ser utilizados para melhorar o desempenho de controladores *fuzzy* apesar

de, em algumas situações, piorar a resposta se comparado a estes.

4.1 Trabalhos futuros

Os resultados obtidos neste trabalho abrem espaço para se projetarem controladores equivalentes aos construídos ao longo dele para controlar um quadrotor real, extrapolando o cenário de simulações.

Referências

BALAS, C. **Modeling and Linear Control of a Quadrotor**. Dissertação (Mestrado) — Cranfield University, Reino Unido, 2007. Citado 2 vezes nas páginas 1 e 2.

GAO, Q.; YUE, F.; HU, D. Research of stability augmentation hybrid controller for quadrotor uav. In: **Control and Decision Conference (2014 CCDC), The 26th Chinese**. [S.l.: s.n.], 2014. p. 5224–5229. Citado na página 5.

MAJ, W.; BUTKIEWICZ, B. Flying n-copter with fuzzy logic control. In: **Signal Processing Symposium (SPS), 2013**. [S.l.: s.n.], 2013. p. 1–6. Citado na página 5.

Apêndices

APÊNDICE A – Código para Criação de Modelo Neuro-Fuzzy para Altitude e Definição de Dados para Treinamento

```
% le arquivo fis referente ao controle de altitude
fismat = readfis('fis_altitude.fis');

% define numero de casos a serem avaliados (treinamento + teste)
n = 300;
% define conjunto de n entradas aleatorias para o sistema fuzzy
% respeitando o range de cada entrada
input = zeros(n,2);
for i=1:n
    z_value = rand * 2 - 1;
    z_dot_value = rand * 10 - 5;
    input(i,:) = [ z_value z_dot_value ];
end

% avalia resposta fuzzy para cada entrada
output= evalfis(input,fismat);

% define data como vetor relacionando cada conjunto de entradas ...
   a saida
% - obtida pelo sistema fuzzy
data = [];
for i=1:n
   data(i,:) = [ input(i,:) output(i) ];
end

% define que 2/3 dos dados obtidos serao usasdos para treinamento
% e 1/3 sera usado para teste da rede
train = data(1:2*n/3,:);     % dados para treinamento
test = data(2*n/3+1:n,:);    % dados para validacao do sistema ...
   treinado

% gera modelo fuzzy Sugeno a partir do Mamdani modelado
sugFIS = mam2sug(fismat);
% salva modelo Sugeno em disco com o nome fis_altitude_neuro.fis
writefis(sugFIS, 'fis_altitude_neuro.fis');
```

APÊNDICE B – Código para Criação de Modelo Neuro-Fuzzy para Atitude e Definição de Dados para Treinamento

```
% le arquivo fis referente ao controle de atitude
fismat = readfis('fis_atitude.fis');

% define numero de casos a serem avaliados (treinamento + teste)
n = 300;
% define conjunto de n entradas aleatorias para o sistema fuzzy
% respeitando o range de cada entrada
input = zeros(n,2);
for i=1:n
    phi_value = rand * 4 - 2;
    phi_dot_value = rand * 3 - 1.5;
    input(i,:) = [ phi_value phi_dot_value ];
end

% avalia resposta fuzzy para cada entrada
output= evalfis(input,fismat);

% define data como vetor relacionando cada conjunto de entradas ...
   a saÃda
% obtida pelo sistema fuzzy
data = [];
for i=1:n
   data(i,:) = [ input(i,:) output(i) ];
end

% define que 2/3 dos dados obtidos serao usasdos para treinamento
% e 1/3 sera usado para teste da rede
train = data(1:2*n/3,:);     % dados para treinamento
test = data(2*n/3+1:n,:);    % dados para validaÃ§Ã£o do sistema ...
   treinado

% gera modelo fuzzy Sugeno a partir do Mamdani modelado
sugFIS = mam2sug(fismat);
% salva modelo Sugeno em disco com o nome fis_atitude_neuro.fis
writefis(sugFIS, 'fis_atitude_neuro.fis');
```