


# 1 Resultados

A Figura 1 mostra a posição no eixo vertical ( $z$ ) do *drone*, bem como sua variação no sistema em que atua o controlador *fuzzy* projetado. Como se pode ver, o distúrbio foi devidamente controlado, fazendo com que o quadricóptero retornasse à posição inicial  $z = -2$  m e também ao repouso<sup>1</sup> representado por  $\dot{z} = 0$  m/s. Nesta figura, entretanto, não fica tão clara a diferença de desempenho dos controladores *fuzzy* e *neuro-fuzzy*, aspecto que pode ser claramente verificado na Figura 2. Como se pode ver, tanto para  $z$  quanto para  $\dot{z}$ , o *neuro-fuzzy* apresenta desempenho melhor. No controle sobre a posição  $z$ , o controlador *neuro-fuzzy* apresentou redução do tempo de convergência em 29%, e da variação do sistema em 31%, além de eliminar a sobrelevação apresentada pelo *fuzzy*. Já sobre a velocidade  $\dot{z}$ , apresentou uma redução no tempo de convergência de 29% além melhorar a variação do sistema em 23%. A partir destes resultados, verifica-se que o controlador *neuro-fuzzy* fez com que o distúrbio fosse melhor absorvido e que sua correção ocorresse mais rapidamente.


Figura 1 – Comparação da resposta das saídas  $z$  e  $\dot{z}$  no controle de altitude *fuzzy* e *neuro-fuzzy* para o sistema com massa  $m = 2$  kg



Já as Figuras 3 e 4 mostram a estabilidade de atitude em torno dos eixos  $x$  e  $y$  (i.e. em relação ao plano horizontal  $XY$ ), representados por  $\theta$  e  $\phi$  respectivamente. Como se pode ver, ambos os estados são devidamente controlados e, com isto, o quadrotor

<sup>1</sup> i.e. velocidade nula

Figura 2 – Comparação em mais detalhes da resposta das saídas  $z$  e  $\dot{z}$  no controle de altitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 2 \text{ kg}$



volta à estabilidade horizontal, com ângulos e velocidades angulares nulas no estado permanente.

Figura 3 – Comparação da resposta das saídas  $\phi$  e  $\dot{\phi}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 2 \text{ kg}$





Figura 4 – Comparação da resposta das saídas  $\theta$  e  $\dot{\theta}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 2kg$



A partir das Figuras 5 e 6, que mostram as respostas obtidas em mais detalhes, pode-se ver que, mais uma vez o controlador neuro-fuzzy mais uma vez teve desempenho superior ao fuzzy, fazendo com que os ângulos  $\phi$  e  $\theta$  convergissem 2% mais rápido, além de reduzir suas variações em 13%. Com relação às velocidades angulares  $\dot{\phi}$  e  $\dot{\theta}$ , foi capaz de reduzir o tempo de convergência em 3%, não afetando a variação nem a sobrelevação apresentada pelo sistema quando estabilizado pelo controlador fuzzy. Desta forma, verifica-se que o controle neuro-fuzzy levou o sistema a uma menor variação, representando que o ângulo máximo de inclinação alcançado pelo drone é menor e corrigido mais rapidamente.

Além da verificação da eficiência dos controladores atuando sobre o sistema para o qual foram projetados, eles foram testados num sistema em que um dos parâmetros foi acrescido de mais de 100 %, com a massa passando de 2,3 kg para 5 kg.

A resposta dos controladores fuzzy e neuro-fuzzy para altitude do drone nessas circunstâncias são mostradas nas Figuras 7 e 8, sendo que esta segunda é apenas uma forma melhor de comparar a ação dos dois controladores. Como se pode perceber, ambos os controladores levaram à estabilização do sistema, sendo que desta vez cada um obteve desempenho melhor sob determinados aspectos. No controle da posição vertical  $z$ , o neuro-fuzzy apresentou tempo de convergência 57% maior, em parte causado por uma sobrelevação, que não foi apresentada pelo fuzzy. Em contrapartida, o neuro-fuzzy apresentou uma menor variação, a reduzindo em 20% se comparado

Figura 5 – Comparação em mais detalhes da resposta das saídas  $\phi$  e  $\dot{\phi}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 2kg$


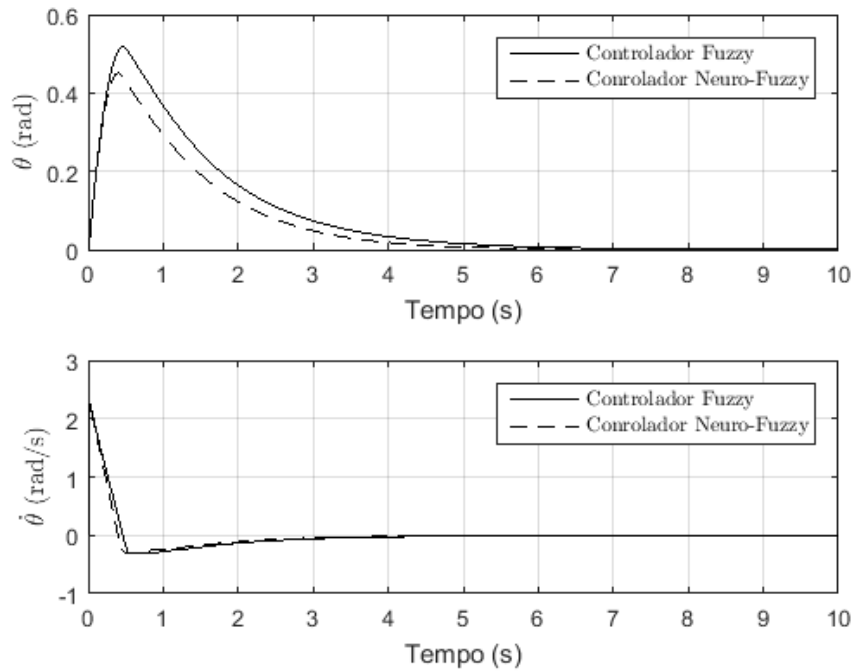



Figura 6 – Comparação em mais detalhes da resposta das saídas  $\theta$  e  $\dot{\theta}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 2kg$



ao fuzzy. Com relação à velocidade  $\dot{z}$ , o controlador neuro-fuzzy apresentou aumento de 23% no tempo de convergência, mas melhorou o sistema nos quesitos variação e sobrelevação, as reduzindo em 16% e 33%, respectivamente. Esses resultados apontam

que o quadrotor, quando submetido ao controle neuro-fuzzy, apresentou movimentos mais suaves até ter sua altitude estabilizada, apesar de ter sido necessário mais tempo para que ela ocorresse.

Figura 7 – Comparação da resposta das saídas  $z$  e  $\dot{z}$  no controle de altitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 5kg$



Por fim, as Figuras 9 e 10 mostram os resultados obtidos pelos controladores de atitude no sistema com massa  $m = 5 kg$ . Percebe-se que mais uma vez o sistema convergiu ao seu estado de estabilidade com os ângulos nulos e velocidades angulares também nulas, representando que o quadrotor, após a ação de controle, tanto fuzzy quanto neuro-fuzzy, fica estável e com orientação plana<sup>2</sup>.

As Figuras 11 e 12 mostram em mais detalhes as repostas obtidas pelos controladores sobre a atitude do sistema com massa  $m = 5 kg$ . A partir delas, nota-se que mais uma vez o controlador neuro-fuzzy apresentou desempenho levemente superior ao fuzzy. Sobre os ângulos  $\phi$  e  $\theta$ , a convergência ocorreu 3% mais rapidamente e a variação apresentada reduziu 14%. Já sobre as velocidades angulares  $\dot{\phi}$  e  $\dot{\theta}$ , a redução de tempo de convergência com o neuro-fuzzy foi de 2%, mantendo a mesma sobrelevação e variação oferecidas pelo fuzzy. Com isto, mais uma vez o controle neuro-fuzzy fez com que o ângulo máximo de inclinação do quadrotor fosse inferior ao alcançado pelo sistema controlado pelo fuzzy, e além de reduzir o tempo necessário para sua estabilização definitiva.

<sup>2</sup> i.e paralela ao plano XY

Figura 8 – Comparação em mais detalhes da resposta das saídas  $z$  e  $\dot{z}$  no controle de altitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 5kg$




Figura 9 – Comparação da resposta das saídas  $\phi$  e  $\dot{\phi}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 5kg$

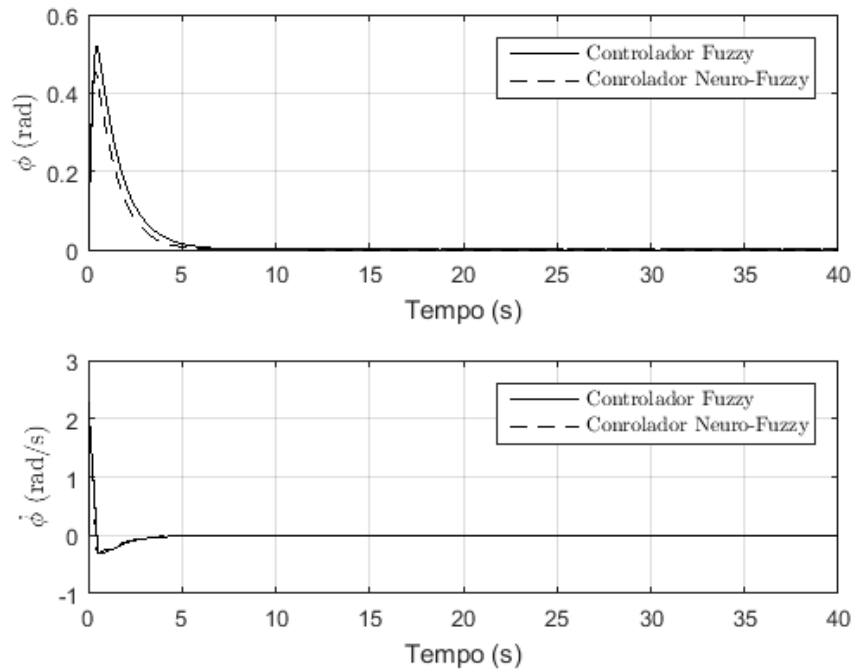


Figura 10 – Comparação da resposta das saídas  $\theta$  e  $\dot{\theta}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 5kg$


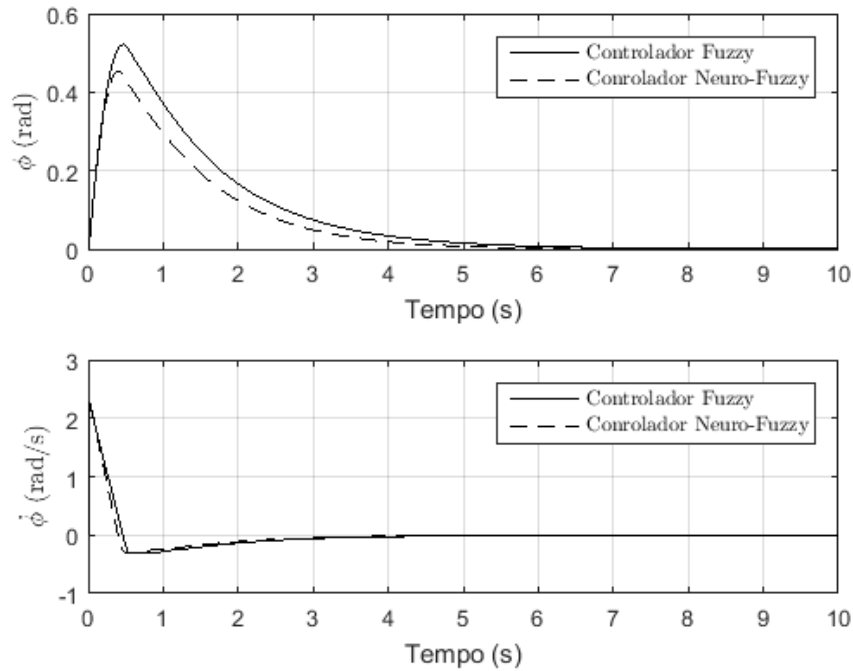



Figura 11 – Comparação da resposta das saídas  $\phi$  e  $\dot{\phi}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 5kg$



## 1.1 Análise Consolidada dos Resultados

Como se pode ver, os controladores de atitude e altitude tanto fuzzy quanto neuro-fuzzy foram eficientes levando à estabilização do sistema em todos os casos

Figura 12 – Comparação da resposta das saídas  $\theta$  e  $\dot{\theta}$  no controle de atitude fuzzy e neuro-fuzzy para o sistema com massa  $m = 5kg$



testados, inclusive na situação em que a massa do sistema foi aumentada em mais de 100 %. Isso indica que estes controladores podem ser utilizados, por exemplo, em situações em que o drone precisaria transportar uma carga que tenha sua massa ou até mesmo uma superior.

Em quase todos os casos, nota-se um comportamento do controlador neuro-fuzzy superior ao do fuzzy, o que já era esperado tendo em vista que o primeiro alia o poder do segundo às vantagens das RNAs, fazendo com que, a partir de um treinamento supervisionado utilizando o próprio modelo fuzzy, possa se construir um controle mais abrangente e com resposta melhorada.

Estes resultados mostram que, de fato, as técnicas de Inteligência Computacional podem ser aplicadas para projetar controladores eficientes e robustos para atuar sobre sistemas multivariável e que, além disto, o poder de treinamento dos ANFISs realmente é capaz de fazer com que o desempenho de controladores neuro-fuzzy seja melhorado se comparado a de controladores puramente fuzzy.



## Referências

## Apêndices

## APÊNDICE A – Código para Criação de Modelo Neuro-Fuzzy para Altitude e Definição de Dados para Treinamento

```

1      % le arquivo fis referente ao controle de altitude
2      fismat = readfis('fis_altitude.fis');
3
4      % define numero de casos a serem avaliados (treinamento + teste)
5      n = 300;
6      % define conjunto de n entradas aleatorias para o sistema fuzzy
7      % respeitando o range de cada entrada
8      input = zeros(n,2);
9      for i=1:n
10         z_value = rand * 2 - 1;
11         z_dot_value = rand * 10 - 5;
12         input(i,:) = [ z_value z_dot_value ];
13     end
14
15     % avalia resposta fuzzy para cada entrada
16     output= evalfis(input,fismat);
17
18     % define data como vetor relacionando cada conjunto de entradas ...
19     % a saida
20     % - obtida pelo sistema fuzzy
21     data = [];
22     for i=1:n
23         data(i,:) = [ input(i,:) output(i) ];
24     end
25
26     % define que 2/3 dos dados obtidos serao usados para treinamento
27     % e 1/3 sera usado para teste da rede
28     train = data(1:2*n/3,:);    % dados para treinamento
29     test = data(2*n/3+1:n,:);  % dados para validacao do sistema ...
30     treinado
31
32     % gera modelo fuzzy Sugeno a partir do Mamdani modelado
33     sugFIS = mam2sug(fismat);
34     % salva modelo Sugeno em disco com o nome fis_altitude_neuro.fis
35     writefis(sugFIS, 'fis_altitude_neuro.fis');

```

## APÊNDICE B – Código para Criação de Modelo Neuro-Fuzzy para Atitude e Definição de Dados para Treinamento

```

1      % le arquivo fis referente ao controle de atitude
2      fismat = readfis('fis_atitude.fis');
3
4      % define numero de casos a serem avaliados (treinamento + teste)
5      n = 300;
6      % define conjunto de n entradas aleatorias para o sistema fuzzy
7      % respeitando o range de cada entrada
8      input = zeros(n,2);
9      for i=1:n
10         phi_value = rand * 4 - 2;
11         phi_dot_value = rand * 3 - 1.5;
12         input(i,:) = [ phi_value phi_dot_value ];
13     end
14
15     % avalia resposta fuzzy para cada entrada
16     output= evalfis(input,fismat);
17
18     % define data como vetor relacionando cada conjunto de entradas ...
19     % a saída
20     % obtida pelo sistema fuzzy
21     data = [];
22     for i=1:n
23         data(i,:) = [ input(i,:) output(i) ];
24     end
25
26     % define que 2/3 dos dados obtidos serao usados para treinamento
27     % e 1/3 sera usado para teste da rede
28     train = data(1:2*n/3,:);    % dados para treinamento
29     test = data(2*n/3+1:n,:);  % dados para validação do sistema ...
30     treinado
31
32     % gera modelo fuzzy Sugeno a partir do Mamdani modelado
33     sugFIS = mam2sug(fismat);
34     % salva modelo Sugeno em disco com o nome fis_atitude_neuro.fis
35     writefis(sugFIS, 'fis_atitude_neuro.fis');

```